Jurnal Algoritma
E-ISSN: 2302-7339 | P-ISSN: 1412-3622
INSTITUT TEKNOLOGI GARUT

https://jurnal.itg.ac.id/index.php/algoritma
DOI: 10.33364/algoritma/v.22-2.2690

Prediksi Dukungan Publik Terhadap Program Makan Bergizi Gratis (MBG) Menggunakan Analisis Sentimen Berbasis *Long Short-Term Memory* (LSTM)

Elma Novfuja[1*], Susanti[2], Edwar Ali[3], Lusiana[4]
[1,2,3,4]Universitas Sains dan Teknologi Indonesia, Indoensia

***email:** elmanovpujaja@gmail.com

Info Artikel
Dikirim: 14 Augustus 2025
Diterima: 14 November 2025
Diterbitkan: 30 November 2025

Kata kunci:
Analisis Sentimen;
Long Short-Term Memory;
Lexicon-Based;
Program Makan Bergizi Gratis;
Word2Vec;

ABSTRAK

Program Makan Bergizi Gratis (MBG) merupakan kebijakan publik yang memerlukan evaluasi berbasis opini masyarakat. Penelitian ini mengembangkan model *Long Short-Term Memory* (LSTM) untuk mengklasifikasikan sentimen publik dari 13.923 ulasan X, diambil menggunakan *library tweet-harvest*. Data diproses dengan pembobotan Word2Vec dan pelabelan *Lexicon-Based*, menghasilkan 73.4% sentimen positif dan 26.6% negatif. Model diuji dengan rasio *train-test split* 60:40, 70:30, 80:20, dan 90:10, dengan performa terbaik pada rasio 80:20 (akurasi 91.71%, presisi 89%, *recall* 90%, F1-*score* 89%). Arsitektur model meliputi lapisan *Embedding*, LSTM (128 unit), *Dropout* (70%), dan *Dense*, dioptimalkan dengan *categorical_crossentropy* dan *Adam*. Evaluasi *confusion matrix* menunjukkan efektivitas model, meskipun kelas negatif lemah akibat ketidakseimbangan *data*. Hasilnya memberikan wawasan untuk memperbaiki implementasi MBG, dengan LSTM unggul menangkap pola teks dibandingkan SVM dan BERT.

1. PENDAHULUAN

Program Makan Bergizi Gratis (MBG) merupakan kebijakan strategis pemerintah Indonesia yang bertujuan meningkatkan kesejahteraan masyarakat melalui pemenuhan kebutuhan gizi anak-anak, sebagai bagian dari upaya penguatan sumber daya manusia [1]. Program Makan Bergizi Gratis (MBG), meningkatkan kualitas sumber daya manusia dengan mengatasi stunting dan gizi buruk melalui penyediaan makanan bergizi bagi anak sekolah, balita, ibu hamil, dan ibu menyusui, sejalan dengan visi Indonesia Emas 2045 [2]. Implementasi MBG melibatkan pemanfaatan pangan lokal dan UMKM untuk mendukung ekonomi daerah, dengan target awal 3 juta penerima manfaat pada kuartal pertama 2025[3] . Keberhasilan MBG memerlukan koordinasi lintas sektor dan evaluasi ketat untuk memastikan dampak positif pada status gizi dan pemberdayaan ekonomi lokal [1]. Analisis sentimen merupakan cara atau metode untuk mengenali (mengidentifikasi) dan membagi atau mengelompokkan pendapat atau opini yang ada di dalam teks. Teknik ini sangat penting dalam memahami pandangan masyarakat terhadap suatu produk, layanan, atau isu tertentu. Analisis sentimen dapat membantu perusahaan dalam mengambil keputusan strategis berdasarkan *feedback* dari pelanggan [4]. Analisis ini juga dapat digunakan dalam penelitian sosial untuk memahami persepsi masyarakat terhadap isu-isu tertentu [5].

Analisis sentimen berbasis kecerdasan buatan (AI) menawarkan pendekatan yang efisien dan akurat untuk memahami persepsi masyarakat [6]. *Deep learning* merupakan pendekatan kecerdasan buatan yang memiliki kemampuan luar biasa dalam memproses *data* kompleks, menyerupai cara kerja jaringan saraf otak manusia. Kecerdasan buatan (*artificial intelligence*) sangat menarik dan penting untuk dipelajari karena keunggulannya dalam meniru cara kerja jaringan saraf otak manusia saat belajar [7]. Salah satu metode yang efektif untuk tugas

ini adalah *Long Short-Term Memory* (LSTM), sebuah model jaringan saraf tiruan yang dirancang untuk menangkap hubungan kontekstual dalam *data* teks berurutan. Berbeda dengan metode tradisional seperti *Support Vector Machine* (SVM) atau Naive Bayes (NB), LSTM memiliki kemampuan unggul dalam memproses teks dengan struktur kompleks dan panjang, menjadikannya sangat relevan untuk menganalisis cuitan X yang bervariasi dalam gaya dan konteks [8]. LSTM mampu menangkap pola jangka panjang dalam data, yang penting untuk memahami nuansa emosi dan makna dalam teks, penelitian yang dilakukan oleh [9], makna dalam teks diartikan sebagai kemampuan model LSTM untuk mengidentifikasi emosi dan konteks tersirat dalam cuitan, seperti sentimen positif, negatif, atau netral, melalui analisis urutan kata dan hubungan antarkata. Penelitian ini menunjukkan bahwa LSTM dapat secara efektif menangkap hubungan semantik dalam teks pendek seperti cuitan X, yang relevan untuk analisis sentimen MBG dalam penelitian ini.

Berdasarkan penelitian terdahulu metode LSTM bagus dalam mengkaji analisis sentimen. Penelitian yang dilakukan Ihsan et al [8], dalam Menganalisis sentimen ulasan film untuk memahami respons public menggunakan pendekatan berbasis machine learning Menggunakan *Bidirectional* LSTM dan *GloVe* untuk *word embedding*, Menunjukan Akurasi model *Bidirectional* LSTM sebesar 71%, dengan presisi 89% untuk sentimen negatif, 72% untuk netral, dan 67% untuk positif. Selanjutnya peneliti yang dilakukan [10], dalam Penerapan Metode *Long Short-Term Memory* dan Word2Vec dalam Analisis Sentimen Ulasan pada Aplikasi *Ferizy* menghasilkan Akurasi model LSTM sebesar 74,2% untuk variasi CBOW, dengan *skip- gram* menghasilkan 88,2%. Setelah itu peneliti yang dilakukan [11], Implementasi *Long Short-Term Memory* (LSTM) dan *Word Embedding* Model pada Analisis Sentimen Layanan Uang Elektronik OVO dan Link Aja menunjukkan Akurasi model LSTM sebesar 79% untuk OVO dan76% untuk *Link* Aja, dengan *recall*, presisi, dan F1-*Score* berkisar antara 67%–84%. berdasarkan peneliti tersebut, membuktikan bahwa *Long Short-Term Memory* (LSTM) bagus dalam menganalisis sentimen. Namun, penelitian terdahulu lebih banyak fokus pada ulasan produk, film, dan layanan digital, sedangkan penerapan LSTM untuk menganalisis sentimen publik terhadap kebijakan sosial, khususnya Program Makan Bergizi Gratis (MBG), masih belum banyak dilakukan.

Oleh karena itu, penelitian ini bertujuan untuk membangun model *Long Short-Term Memory* (LSTM) yang mampu mengklasifikasikan sentimen masyarakat terhadap Program MBG berdasarkan data X dengan tingkat akurasi yang tinggi. Kontribusi penelitian ini adalah memberikan pemahaman empiris mengenai persepsi publik terhadap program MBG melalui pendekatan *deep learning* , sekaligus memperluas cakupan aplikasi LSTM pada analisis domain kebijakan sosial di Indonesia.

2. METODELOGI PENELITIAN

Bagian ini menjelaskan langkah-langkah penelitian yang akan dilakukan, seperti yang terlihat pada Gambar 1. Tahap pertama pengumpulan data, selanjutnya *preprocessing* data, spliting data, penerapan model, evaluasi model, dan hasil.

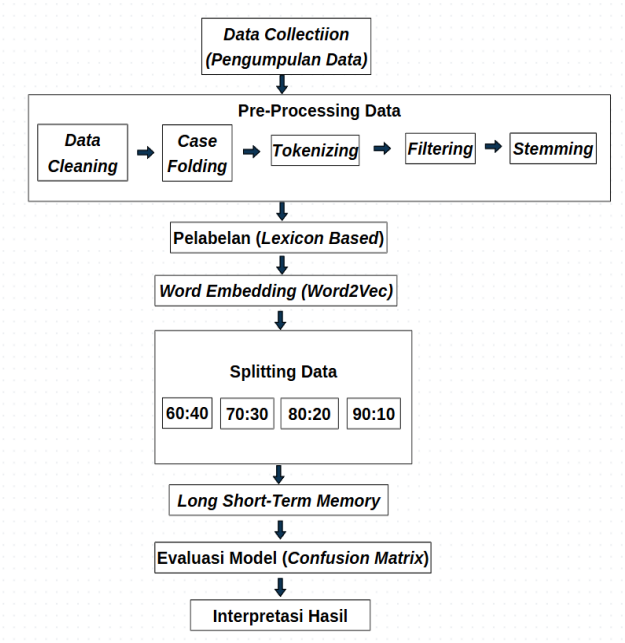

Gambar 1. Alur Penelitian

2.1 Pengumpulan Data

Penelitian ini memanfaatkan data yang diperoleh dari media sosial yaitu X dengan menggunakan teknik *data crawling* dengan *library tweet harvest*. Pada *data* crawling digunakan kata kunci "MBG" dan "makan bergizi gratis" untuk mengambil semua komentar yang berhubungan dengan MBG atau makan bergizi gratis pada tahun 2025. Menggunakan teknik *crawling*, *data* yang didapatkan adalah 13923 *data*. Hasil dari teknik tersebut mendapatkan *data* yang masih mentah, dapat dilihat pada gambar 2.

	conversation_id_str	created_at	favorite_count	full_text	id_str	image_url	in_reply_to_screen_name
0	1814232945538007208	Fri Jul 19 09:36:55 +0000 2024	0	@STresnowati1 moga saja PTUN membatalkan pelan...	1814232945538007208	NaN	STresnowati1
1	1814232671591276830	Fri Jul 19 09:35:50 +0000 2024	0	Warga Solo masih mengucapkan #TerimaKasihMasGi...	1814232671591276830	https://pbs.twimg.com/ext_tw_video_thumb/18142...	NaN
2	1814156048871379204	Fri Jul 19 09:34:11 +0000 2024	0	@iyehmilanistii @StefanAntonio_ Itulah bodohn...	1814232257495982551	NaN	iyehmilanistii
3	1814232124473692537	Fri Jul 19 09:33:39 +0000 2024	8	PDIP Yakin PTUN akan Putuskan KPU tidak Sah Te...	1814232124473692537	NaN	NaN
4	1810548803512217718	Fri Jul 19 09:33:28 +0000 2024	0	@gibran_tweet Samsul soal Makan Bergizi Gratis...	1814232075555451084	https://pbs.twimg.com/media/GS1ydPjbMAA6xvq.jpg	gibran_tweet
...	...	...	...	...	...	...	...

Gambar 2. Pengumpulan data di X

2.2 *Pre-processing Data*

Preprocessing data dalam penelitian ini terdiri dari beberapa langkah, yaitu Setelah data diperoleh, tahap selanjutnya adalah melakukan pra-pemrosesan teks untuk mengubah data mentah menjadi data yang siap digunakan dalam analisis. Proses ini bertujuan meningkatkan kualitas data sehingga hasil analisis menjadi lebih akurat dan andal. Dalam penelitian ini, pra-pemrosesan mencakup lima tahapan, yaitu: (1) data cleaning untuk menghapus elemen yang tidak relevan seperti tautan, tagar, emotikon, simbol, dan mention guna meminimalkan noise; (2) case folding untuk mengubah seluruh huruf menjadi kecil secara seragam guna meningkatkan konsistensi representasi teks; (3) tokenizing untuk memecah teks menjadi unit kata atau token individu berdasarkan pemisah seperti spasi; (4) filtering untuk menghapus kata yang dianggap tidak relevan, seperti stop words, agar hanya kata bermakna yang dipertahankan; dan (5) stemming untuk mengubah kata

berimbuhan menjadi bentuk dasar atau akar katanya dengan menghapus prefiks, sufiks, atau infiks, sehingga konsistensi kata terjaga dan analisis dapat dilakukan dengan lebih optimal.

2.3 Pembelahan Data *(Lexicon-Based)*

Setelah tahap pra-pemrosesan, dilakukan pelabelan data secara otomatis menggunakan metode lexicon-based. Proses ini mengategorikan teks berdasarkan sentimen dengan membandingkan kata-kata dalam teks terhadap daftar kata yang memiliki skor sentimen, sehingga menghasilkan dua kategori, yaitu positif dan negatif. Sentimen positif mencerminkan pandangan yang mendukung atau optimis, sedangkan negatif menunjukkan pandangan yang kritis atau tidak mendukung. Meskipun bersifat otomatis, pelabelan tetap disertai pemeriksaan manual untuk memastikan akurasi, khususnya dengan mempertimbangkan nuansa linguistik dan budaya dalam bahasa Indonesia. Metode ini dipilih karena mampu memproses data teks dalam jumlah besar secara konsisten dan efisien.

2.4 Pembobotan Kata *(*Word2Vec*)*

Tahap selanjutnya setelah pelabelan data adalah pembobotan kata menggunakan metode Word2Vec. Proses ini diawali dengan memasukkan teks yang telah melalui tahap pra-pemrosesan, meliputi *case folding*, *tokenizing*, *filtering*, dan *stemming*, sehingga terbentuk korpus kata yang bersih. Korpus ini digunakan untuk melatih model Word2Vec dalam menghasilkan representasi vektor kata berdasarkan konteks kemunculan nya. Pelatihan dilakukan dengan mengoptimalkan parameter, seperti ukuran *vektor (vector size)* dan jendela konteks *(window size)*, sehingga diperoleh representasi kata yang mampu menangkap hubungan semantik dan sintaksis antar kata. *Vektor* kata yang dihasilkan kemudian diaplikasikan pada tugas pemrosesan bahasa alami, seperti klasifikasi sentimen pada dataset berlabel positif dan negatif. Proses ini dilakukan secara iteratif untuk menyempurnakan representasi kata berdasarkan pola konteks dalam data, dengan penyesuaian parameter yang bertujuan untuk memastikan kualitas representasi optimal. Hasil pembobotan kata ini menjadi fondasi penting bagi pembangunan model predikatif yang akurat dalam penelitian ini.

2.5 Splitting Data

Setelah tahap pembobotan kata menggunakan Word2Vec, proses selanjutnya adalah splitting data, yaitu membagi dataset menjadi data latih (training data) dan data uji (testing data) dengan rasio tertentu. Data latih digunakan untuk membangun model klasifikasi sentimen, sedangkan data uji digunakan untuk mengevaluasi performa model. Pembagian ini bertujuan memastikan bahwa model yang dihasilkan memiliki kemampuan generalisasi yang baik terhadap data baru yang belum pernah dilihat sebelumnya. Pada penelitian ini, pengujian dilakukan sebanyak empat kali dengan variasi rasio pembagian data, yaitu 60:40, 70:30, 80:20, dan 90:10. Rincian jumlah data latih dan data uji pada setiap rasio ditunjukkan pada Tabel 1.

Penelitian ini tidak menggunakan metode *k-fold cross-validation* karena pertimbangan efisiensi komputasi. Proses pelatihan model berbasis Word2Vec dan LSTM membutuhkan sumber daya komputasi yang cukup besar, sehingga penggunaan cross-validation akan memperbanyak waktu pelatihan secara signifikan. Sebagai gantinya, penelitian ini menggunakan empat variasi rasio pembagian data (60:40, 70:30, 80:20, dan 90:10) untuk mengevaluasi kestabilan performa model. Dengan cara ini, penelitian tetap dapat menilai kemampuan generalisasi model pada berbagai proporsi data latih dan data uji tanpa beban komputasi yang terlalu tinggi.

Tabel 1. Hasil Evaluasi Model *SVM* Tanpa *Smote* Splitting Data 80:20

Splitting Data	Data Latih	Data Uji
60:40	8353	5570
70:30	9746	4177
80:20	11138	2785
90:10	12530	1393

2.6 *Long Short-Term Memory* (LSTM)

Long Short-Term Memory (LSTM) adalah salah satu arsitektur dari *Recurrent Neural Network (RNN)* yang dirancang untuk menangani masalah ketergantungan temporal dalam data berurutan. LSTM adalah pengembangan dari *RNN* yang mampu mengatasi masalah vanishing gradient dengan menggunakan struktur gerbang *(gates)* seperti *input gate, forget gate*, dan *output gate* untuk mengatur aliran informasi [12]. Struktur ini memungkinkan LSTM untuk secara efektif mengingat informasi jangka panjang, yang sangat penting dalam pemrosesan data runtun waktu. LSTM memahami hubungan antar kata dan makna kata dalam konteks, sehingga cocok untuk analisis sentimen yang memerlukan pemahaman urutan data [13]. LSTM sangat relevan digunakan untuk menganalisis sentimen publik mengenai Program Makan Bergizi Gratis (MBG). Hal ini karena data sentimen publik umumnya berupa teks yang memiliki keterkaitan antar kata dalam urutan tertentu. Kemampuan LSTM dalam memahami hubungan temporal antar kata memungkinkan klasifikasi opini masyarakat baik positif, maupun negatif dapat dilakukan dengan lebih akurat. Gambar 3 menunjukkan struktur dari LSTM.

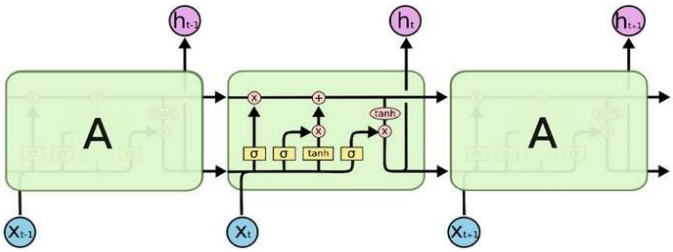

Gambar 3. Struktur LSTM

Gambar 3 menunjukkan arsitektur *Long Short-Term Memory* (LSTM) yang terdiri dari sel memori dan tiga jenis gerbang utama, yaitu input gate, forget gate, dan output gate, yang berfungsi mengatur aliran informasi serta mendukung pemrosesan data berurutan. LSTM mampu menyimpan informasi jangka panjang melalui cell state, sehingga efektif digunakan dalam analisis data berurutan seperti komentar dari platform X [14][15].

1. *Forget gate*
   Merupakan lapisan pertama dari jaringan saraf *Long Short-Term Memory* (LSTM) berfungsi mengatur jumlah informasi yang akan disimpan dan menghilangkan informasi yang tidak dibutuhkan.
2. *Input gate*
   Merupakan lapisan kedua dari jaringan saraf *Long Short-Term Memory* (LSTM) berfungsi memasukkan informasi berguna untuk mendukung keakuratan *data.*
3. *Output gate*
   Merupakan lapisan terakhir dari jaringan saraf *Long Short-Term Memory* (LSTM) berfungsi mengatur jumlah *state* yang melalui *output* dan bekerja sama dengan *gate* lain serta menghasilkan nilai *hidden state*. *Hidden state* merupakan pengaruh nilai yang diproses selanjutnya, di mana nilai diperoleh dengan mengalikan nilai *output* dengan nilai dari *memory cell* atau *cell state* yang diaktifkan dengan fungsi *tanh*.

2.7 Evaluasi Model

Setelah penerapan model *Long Short-Term Memory* (LSTM) pada dataset obesitas, langkah berikutnya adalah Evaluasi model mengukur performa klasifikasi *data* secara akurat menggunakan *confusion matrix*. Metrik akurasi, presisi, *recall*, dan F1-*score* mengevaluasi prediksi untuk kelas positif dan negatif. Metrik-metrik ini dipilih karena mampu memberikan gambaran menyeluruh mengenai performa model, khususnya pada kasus klasifikasi sentimen yang sering menghadapi ketidakseimbangan data antar kelas. Akurasi menunjukkan proporsi prediksi yang benar secara keseluruhan, presisi mengukur ketepatan prediksi pada kelas tertentu, recall menilai kemampuan model dalam menangkap semua data dari suatu kelas, sedangkan F1-score menggabungkan presisi dan recall untuk menyeimbangkan keduanya[4]. Akurasi tinggi menunjukkan model handal, memberikan hasil prediksi yang detail dan konsisten untuk analisis sentimen.

3. HASIL DAN PEMBAHASAN

Pada tahap ini, penelitian meliputi pengumpulan *data*, pembersihan *data*, pelabelan *data*, pembagian *data* menjadi *data* latih dan *data* uji, pembuatan representasi *word embedding*, penerapan algoritma *Long Short-Term Memory*, Skema pengujian dilakukan dengan menggunakan pembagian data 60:40, 70:30, 80:20, dan 90:10. evaluasi performa model menggunakan *confusion matrix*, serta perhitungan nilai akurasi. Analisis hasil klasifikasi dilakukan untuk memberikan wawasan mengenai kebijakan makan bergizi gratis.

3.1 *Data Collection*

Tahap awal melakukan pengumpulan data dari platform X. Untuk dapat mengakses data, diperlukan auth_token yang disediakan oleh platform X. Proses perolehannya dilakukan dengan membuka menu *Tools* > *Application* > *Cookies*, kemudian mencari parameter auth_token dan menyimpannya. Auth_token tersebut selanjutnya digunakan dalam proses pengambilan data (data crawling). Pada tahap ini, pencarian dilakukan menggunakan kata kunci "makan bergizi gratis" dengan periode pengambilan data pada tahun 2025. Proses data crawling berhasil mengumpulkan data pada rentang waktu 1 September 2024 hingga 10 Juni 2025, dengan total sebanyak 13923 entri data.

Pemilihan rentang waktu ini didasarkan pada alasan bahwa program Makan Bergizi Gratis (MBG) mulai ramai diperbincangkan publik sejak diumumkan secara resmi menjelang akhir tahun 2024, dan diskusi mengenai program tersebut terus berlanjut hingga pertengahan tahun 2025. Dengan demikian, periode ini dianggap representatif untuk menangkap persepsi dan sentimen publik yang relevan terhadap implementasi awal program MBG.

3.2 *Preprocessing*

Proses *preprocessing* dilakukan untuk meningkatkan kualitas data, sehingga dapat menghasilkan analisis yang lebih akurat dan andal. Pada penelitian ini, tahapan pra-pemrosesan teks meliputi lima langkah utama.

3.2.1 *Cleaning*

Pada tabel 2, *Cleaning* bertujuan menghapus elemen-elemen yang tidak diinginkan seperti emoji, *URL*, tanda baca, simbol, underscore, angka, dan spasi berlebih, sehingga teks menjadi lebih bersih dan terstandarisasi untuk keperluan analisis atau pemrosesan lebih lanjut, seperti analisis sentimen atau pemodelan machine learning.

Tabel 2. *Data Cleaning*

Komentar	***Data Cleaning***
Dari semua efisiensi & untuk danantara katanya Ternyata ada pemotongan ke sini juga alasannya apa? Gajelas. Mungkin klo pak @prabowo selama ini ngasih efisiensi dengan alasan yang jelas tujuan yg jelas bisa kita pahamin Plis… alasan untuk MBG/danantara bullshit ga sih..	Dari semua efisiensi amp untuk danantara katanya Ternyata ada pemotongan ke sini juga alasannya apa? Gajelas. Mungkin klo pak prabowo selama ini ngasih efisiensi dengan alasan yang jelas tujuan yang jelas bisa kita pahamin. Alasan untuk MBG/danantara omong kosong.
@berlianidris @prabowo Ini program bancaan dia lho dkk .. ini lah program pencucian uang dia… apa lagi kalo bukan MBG ini? Potong kuping saya kalo Indonesia bakal aman keuangannya dari korupsi selama program MBG ini masih lah.	Ini program bancaan dia, ini lah program pencucian uang dia. Apa lagi kalo bukan MBG ini? Potong kuping saya kalo Indonesia bakal aman keuangannya dari korupsi selama program MBG ini masih.
@berlianidris @prabowo Kasih kerjaan kepada ortu siswa yang layak biar bisa makan sesuai standar pemerintah bukan ksh MBG kalau nggak bisa menjalankan sesuai standar kenapa harus dipaksakan toh anak ini mengatakan sesuat fakta.	Kasih kerjaan kepada ortu siswa yang layak biar bisa makan sesuai standar pemerintah bukan ksh MBG. Kalau nggak bisa menjalankan sesuai standar kenapa harus dipaksakan toh anak ini mengatakan sesuatu fakta.

3.2.2 *Case Folding*

Setelah itu masuk ketahap *case folding*, *case folding* ini bertujuan untuk menghilangkan perbedaan huruf kapital dan kecil, sehingga memastikan konsistensi teks untuk mempermudah analisis atau pemrosesan data

lebih lanjut, seperti klasifikasi teks, analisis sentimen, atau pemodelan *machine learning*, dengan mengurangi variasi yang tidak perlu dalam data. Hasil dari *case folding* terlihat pada tabel 3.

Tabel 3. *Case Folding*

Data Cleaning	***Case Folding***
Dari semua efisiensi amp untuk danantara katanya Ternyata ada pemotongan ke sini juga alasannya apa Gajelas Mungkin klo pak selama ini ngasih efisiensi dengan alasan yang jelas tujuan yang jelas bisa kita pahamin Tolong alasan untuk MBGdanantara omong kosong tidak sih	dari semua efisiensi amp untuk danantara katanya ternyata ada pemotongan ke sini juga alasannya apa gajelas mungkin klo pak selama ini ngasih efisiensi dengan alasan yang jelas tujuan yang jelas bisa kita pahamin tolong alasan untuk mbgdanantara omong kosong tidak sih
Ini program bancaan dia lho dkk ini lah program pencucian uang dia apa lagi kalo bukan MBG ini Potong kuping saya kalo Indonesia bakal aman keuangannya dari Korupsi selama program MBG ini masih halah halah	ini program bancaan dia loh dkk ini lah program pencucian uang dia apa lagi kalo bukan mbg ini potong kuping saya kalo indonesia bakal aman keuangannya dari korupsi selama program mbg ini masih halah halah
Kasih kerjaan kepada orang tua siswa yang layak biar bisa makan sesuai standar pemerintah bukan ksh MBG kalau memang tidak bisa menjalankan sesuai standar kenapa harus dipaksakan toh anak ini mengatakan sesuai fakta	kasih kerjaan kepada orang tua siswa yang layak biar bisa makan sesuai standar pemerintah bukan ksh mbg kalau memang tidak bisa menjalankan sesuai standar kenapa harus dipaksakan toh anak ini mengatakan sesuai fakta

3.2.3 *Tokenizing*

Selanjutnya pada tabel 4, proses tokenisasi ini merupakan langkah penting dalam pemrosesan teks, seperti analisis sentimen atau pemodelan *machine learning*, karena memungkinkan teks dipecah menjadi unit-unit kata yang lebih mudah dianalisis atau diproses lebih lanjut. Fungsi ini memastikan bahwa hanya kata-kata yang valid (tidak kosong) yang disimpan dalam daftar hasil, sehingga meningkatkan kualitas data untuk tahapan analisis berikutnya.

Tabel 4. *Tokenizing*

Case Folding	***Tokenizing***
dari semua efisiensi amp untuk danantara katanya ternyata ada pemotongan ke sini juga alasannya apa gajelas mungkin kalau pak selama ini ngasih efisiensi dengan alasan yang jelas tujuan yang jelas bisa kita pahamin tolong alasan untuk mbgdanantara omong kosong tidak sih	[dari, semua, efisiensi, amp, untuk, danantara, katanya, ternyata, ada, pemotongan, ke, sini, juga, alasannya, apa, gajelas, mungkin, kalau, pak, selama, ini, ngasih, efisiensi, dengan, alasan, yang, jelas, tujuan, yang, jelas, bisa, kita, pahamin, tolong, alasan, untuk, mbgdanantara, omong, kosong, tidak, sih]
ini program bancaan dia loh dkk ini lah program pencucian uang dia apa lagi kalo bukan mbg ini potong kuping saya kalo indonesia bakal aman keuangannya dari korupsi selama program mbg ini halah halah	[ini, program, bancaan, dia, loh, dkk, ini, lah, program, pencucian, uang, dia, apa, lagi, kalo, bukan, mbg, ini, potong, kuping, saya, kalo, indonesia, bakal, aman, keuangannya, dari, korupsi, selama, program, mbg, ini, halah, halah]
kasih kerjaan kepada orang tua siswa yang layak biar bisa makan sesuai standar pemerintah bukan ksh mbg kalau memang tidak bisa menjalankan sesuai standar kenapa harus dipaksakan toh anak ini mengatakan sesuai fakta	[kasih, kerjaan, kepada, orang, tua, siswa, yang, layak, biar, bisa, makan, sesuai, standar, pemerintah, bukan, ksh, mbg, kalau, memang, tidak, bisa, menjalankan, sesuai, standar, kenapa, harus, dipaksakan, toh, anak, ini, mengatakan, sesuai, fakta]

3.2.4 *Filtering*

Masuk ke filtering, bertujuan untuk melakukan penghapusan stopwords, yaitu kata-kata umum yang tidak memiliki makna signifikan seperti "dan", "di", atau "dari", dari data teks dalam kolom 'Komentar' pada *dataFrame df.* Fungsi *stopword_removal* menerima input berupa list kata dan menggunakan daftar *stopwords* dari bahasa Indonesia yang diambil dari library *stopwords.* Hasil dari *filtering* terlihat pada tabel 5.

Tabel 5. *Filtering*

Tokenizing	***Filtering***
dari, semua, efisiensi, amp, untuk, danantara, katanya, ternyata, ada, pemotongan, ke, sini, juga, alasannya, apa, gajelas, mungkin, kalau, pak, selama, ini, ngasih, efisiensi, dengan, alasan, yang, jelas, tujuan, yang, jelas, bisa, kita, pahamin, tolong, alasan, untuk, mbgdanantara, omong, kosong, tidak, sih]	[semua, efisiensi, amp, danantara, katanya, ternyata, pemotongan, sini, alasannya, gajelas, mungkin, pak, selama, ngasih, efisiensi, alasan, jelas, tujuan, jelas, kita, pahamin, tolong, mbgdanantara, omong, kosong, sih]

Tokenizing	*Filtering*
[ini, program, bancaan, dia, loh, dkk, ini, lah, program, pencucian, uang, dia, apa, lagi, kalo, bukan, mbg, ini, potong, kuping, saya, kalo, indonesia, bakal, aman, keuangannya, nya, dari, korupsi, selama, program, mbg, ini, halah, halah]	[program, bancaan, loh, dkk, program, pencucian, uang, kalo, mbg, potong, kuping, indonesia, bakal, aman, keuangan, korupsi, selama, program, mbg, halah]
[kasih, kerjaan, kepada, orang, tua, siswa, yang, layak, biar, bisa, makan, sesuai, standar, pemerintah, bukan, ksh, mbg, kalau, memang, tidak, bisa, menjalankan, sesuai, standar, kenapa, harus, dipaksakan, toh, anak, ini, mengatakan, sesuai, fakta]	[kasih, kerjaan, orang, tua, siswa, layak, biar, makan, sesuai, standar, pemerintah, ksh, mbg, kalau, memang, bisa, menjalankan, sesuai, standar, dipaksakan, anak, mengatakan, sesuai, fakta]

3.2.5 *Stemming*

Terakhir tahap *stemming*, bertujuan untuk data teks dalam kolom 'Komentar' dari dataFrame df, yaitu proses mengubah kata-kata ke bentuk dasarnya (misalnya, "bergizi" menjadi "gizi") untuk menyederhanakan analisis teks. Hasil *stemming* dapat diihat pada tabel 6.

Tabel 6. *Stemming*

Filtering	*Stemmed_text*
[semua, efisiensi, amp, danantara, katanya, ternyata, pemotongan, sini, alasannya, apa, gajelas, mungkin, kalau, pak, selama, ngasih, efisiensi, alasan, jelas, tujuan, jelas, kita, pahamin, alasan, mbgdanantara, omong, kosong, sih]	semua efisiensi amp danantara kata nyata potong sini alas apa gajelas mungkin kalau pak lama ngasih efisiensi alas jelas tuju jelas kita pahamin alas mbgdanantara omong kosong sih
[program, bancaan, loh, dkk, program, pencucian, uang, apa, kalo, bukan, mbg, potong, kuping, kalau, indonesia, bakal, aman, keuangan, nya, korupsi, selama, program, mbg, halah]	program bancaan loh dok lah program cuci uang apa kalo bukan mbg potong kuping kalau indonesia bakal aman nya korupsi lama program mbg halah
[kasih, kerjaan, orang, tua, siswa, layak, biar, makan, sesuai, standar, pemerintah, bukan, ksh, mbg, kalau, memang, bisa, menjalankan, sesuai, standar, harus, dipaksakan, anak, mengatakan, sesuai, fakta]	kasih kerja orang tua siswa layak biar makan sesuai standar perintah bukan ksh mbg kalau memang bisa jalan sesuai standar harus paksa anak kata sesuai fakta

3.3 Hasil Pelabelan Data *(Lexicon Based)*

Pada Gambar 4, menunjukkan hasil pelabelan otomatis menggunakan *lexicon-based* terhadap 13.923 data komentar. Proses ini dilakukan dengan mencocokkan setiap kata dalam komentar terhadap daftar kata *positif* dan *negatif* yang telah diberi bobot, kemudian menentukan label sentimen dengan kode 1 untuk positif dan 0 untuk negatif. Implementasi dilakukan penentuan label menggunakan aturan *label = 1 if score > 0 else 0.* Hasil analisis menunjukkan bahwa sebanyak 10.223 komentar (73,4%) dikategorikan positif dan 3.700 komentar (26,6%) negatif. Distribusi ini menunjukkan dominasi komentar positif dalam dataset, yang menjadi pertimbangan penting pada tahap pemrosesan data selanjutnya.

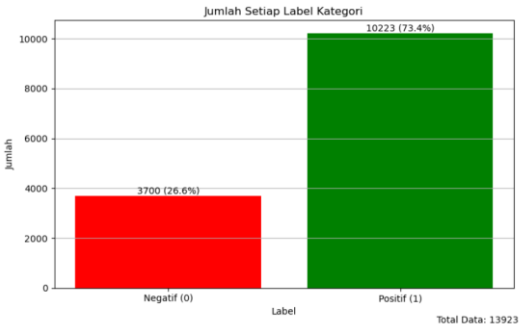

Gambar 4. Distribusi Label

Setelah proses pelabelan otomatis dilakukan dan setiap teks memperoleh kode label biner 1 untuk positif dan 0 untuk negatif, data tersebut kemudian diproses lebih lanjut pada tahap ekstraksi fitur menggunakan Word2Vec. Metode ini mengubah setiap kata menjadi representasi vektor berdimensi tetap, sehingga informasi semantik dan hubungan antar kata dalam teks dapat dipertahankan untuk analisis sentimen pada tahap berikutnya.

3.4 Pembobotan Kata (Word2Vec)

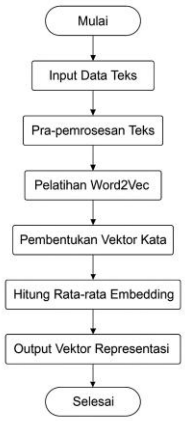

Gambar 5. Alur Word2Vec

Pada Gambar 5, Flowchart ini menggambarkan proses pembobotan kata menggunakan Word2Vec. Proses dimulai dari *input data teks* hasil pengumpulan, kemudian dilakukan *pra-pemrosesan teks* seperti tokenisasi, case folding, dan penghapusan stopword agar data lebih bersih. Selanjutnya dilakukan *pelatihan model* Word2Vec dengan parameter tertentu (*vector size*, *window*, *min_count*, dan *workers*) untuk menghasilkan representasi vektor.

Untuk melatih model Word2Vec menggunakan *pustaka Gensim*, yang mengubah setiap kata dalam kumpulan kalimat menjadi representasi vektor embedding berdimensi 100 berdasarkan konteks kemunculannya. Parameter *window=5* menentukan jumlah kata di sekitar target yang diperhitungkan, *min_count=1* memastikan semua kata digunakan walaupun hanya muncul sekali, dan *workers=4* memungkinkan pelatihan paralel dengan empat thread untuk meningkatkan efisiensi. Hasil pelatihan menampilkan 10 kata pertama beserta vektor *embedding*-nya, di mana setiap kata direpresentasikan dalam bentuk vektor berdimensi 100 dengan bobot yang berbeda, mencerminkan perbedaan makna semantik antar kata.

3.5 Hasil Model *Long Short-Term Memory* (LSTM)

Selanjutnya mengolah data menggunakan algoritma *Long Short-Term Memory* (LSTM), model yang dibangun menggunakan Sequential terdiri dari beberapa lapisan yang dioptimalkan untuk tugas klasifikasi teks. Lapisan pertama adalah *Embedding* yang mengubah kata menjadi *vektor* berdimensi 100 dengan panjang input maksimum 100, menghasilkan 1.409.100 parameter terlatih untuk merepresentasikan kata berdasarkan konteksnya. Selanjutnya, lapisan LSTM dengan 128 unit (117.248 parameter) digunakan untuk menangkap pola urutan dalam data, diikuti oleh lapisan *Dropout* dengan tingkat 70% untuk mencegah *overfitting*. Lapisan Dense pertama memiliki 64 unit dengan aktivasi *ReLU* (8.256 parameter), dan lapisan output memiliki 2 unit dengan aktivasi *softmax* (195 parameter) untuk mengklasifikasikan data menjadi dua kelas. Model ini dikompilasi menggunakan fungsi loss *categorical_crossentropy*, *optimizer Adam*, dan *metrik akurasi*. Kemudian dilatih selama *20 epoch* dengan *batch size 64* menggunakan data latih dan validasi untuk memastikan performa optimal. Evaluasi dilakukan dengan menghitung akurasi melalui perbandingan label prediksi dan label sebenarnya, serta membuat confusion matrix untuk menganalisis distribusi prediksi benar dan salah per kelas. *Matrik*s ini divisualisasikan sebagai heatmap berukuran 8x6 inci dengan label kelas yang jelas dan skema warna biru, memudahkan interpretasi pola kesalahan klasifikasi. Arsitektur LSTM ini menunjukkan efektivitas dalam klasifikasi teks, dengan potensi peningkatan performa melalui penyesuaian *hyperparameter* atau penambahan data pelatihan guna meningkatkan model pada dataset yang lebih besar.

Tabel 7. Parameter *Long Short-Term Memory* (LSTM)

Layer (Type)	Output Shape	Param #
Embedding	(None, 100, 100)	983900
LSTM	(None, 128)	117248
Dropout	(None, 128)	0
Dense	(None, 64)	8256
Dense_1	(None, 2)	195
Total params		1109599 (4.23 MB)
Trainable params		1109599 (4.23 MB)
Non-trainable params		0 (0.00 Byte)

3.3 Hasil Evaluasi Model

Selanjutnya dilakukan evaluasi terhadap model *Long Short-Term Memory* (LSTM), dengan pengujian dilakukan sebanyak empat kali dengan variasi rasio pembagian data, yaitu 60:40, 70:30, 80:20, dan 90:10. Proses evaluasi ini dilakukan dengan menggunakan sejumlah metrik yang umum digunakan dalam analisis klasifikasi, antara lain *akurasi, presisi, recall, F1-Score,* dan *Confusion Matrix.*

```
Akurasi LSTM spltiing data 60:40: 91.33%
Classification Report LSTM spltiing data 60:40:
              precision    recall  f1-score   support

     Negatif       0.81      0.87      0.84      1466
     Positif       0.95      0.93      0.94      4104

    accuracy                           0.91      5570
   macro avg       0.88      0.90      0.89      5570
weighted avg       0.92      0.91      0.91      5570
```

```
Akurasi LSTM spltiing data 70:30: 91.21%
Classification Report LSTM spltiing data 70:30:
              precision    recall  f1-score   support

     Negatif       0.83      0.83      0.83      1096
     Positif       0.94      0.94      0.94      3081

    accuracy                           0.91      4177
   macro avg       0.89      0.89      0.89      4177
weighted avg       0.91      0.91      0.91      4177
```

```
Akurasi LSTM spltiing data 80:20: 91.71%
Classification Report LSTM spltiing data 80:20:
              precision    recall  f1-score   support

     Negatif       0.83      0.86      0.85       739
     Positif       0.95      0.94      0.94      2046

    accuracy                           0.92      2785
   macro avg       0.89      0.90      0.89      2785
weighted avg       0.92      0.92      0.92      2785
```

```
Akurasi LSTM spltiing data 90:10: 91.39%
Classification Report LSTM spltiing data 90:10:
              precision    recall  f1-score   support

     Negatif       0.85      0.82      0.84       372
     Positif       0.93      0.95      0.94      1021

    accuracy                           0.91      1393
   macro avg       0.89      0.88      0.89      1393
weighted avg       0.91      0.91      0.91      1393
```

Gambar 6. Model LSTM splitting 60:40,70:30, 80:20 dan 90:10

Pada Gambar 6 diatas, terlihat evaluasi model LSTM pada analisis sentimen Program Makan Bergizi Gratis (MBG) di platform X dengan empat skenario splitting data, yaitu 60:40, 70:30, 80:20, dan 90:10. Hasil pengujian menunjukkan bahwa pada split 60:40 model memperoleh akurasi sebesar 91,33%, dengan precision 0,81 dan recall 0,87 untuk kelas negatif, serta precision 0,95 dan recall 0,93 untuk kelas positif. Pada skenario 70:30, akurasi model sedikit menurun menjadi 91,21%, dengan performa yang relatif seimbang antara kedua kelas. Sementara itu, skenario 80:20 menghasilkan akurasi tertinggi, yaitu 91,71%, menunjukkan kestabilan performa model meskipun data latih lebih sedikit dibanding skenario sebelumnya. Terakhir, pada skenario 90:10, akurasi yang diperoleh adalah 91,39%, dengan sedikit penurunan pada recall kelas negatif. Secara keseluruhan, hasil ini menunjukkan bahwa model LSTM mampu mempertahankan akurasi di atas 91% pada semua variasi pembagian data, yang mengindikasikan kemampuan generalisasi yang baik terhadap data analisis sentimen MBG.

Dari hasil pengujian pada berbagai proporsi data, terlihat bahwa perbedaan akurasi antar skenario pembagian data 80:20 memberikan capaian akurasi tertinggi dibandingkan skenario lainnya. Oleh karena itu, pada tahap selanjutnya, confusion matrix untuk skenario ini digunakan sebagai acuan evaluasi, karena dapat memberikan gambaran paling optimal mengenai kemampuan model dalam mengklasifikasikan data uji.

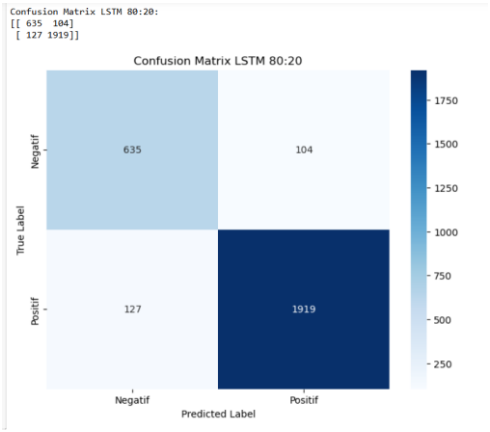

Gambar 7. *Confusion Matrix Splitting* data 80:20

Penjelasan *confusion matrix* pada Gambar 7, pengujian model LSTM dengan proporsi pembagian data sebesar 80:20, diperoleh hasil confusion matrix yang menunjukkan kinerja model dalam melakukan klasifikasi. Sebanyak 635 data dengan kelas negatif berhasil diprediksi dengan benar *True Negative*, sedangkan 104 data negatif lainnya keliru diprediksi sebagai positif *False Positive*. Untuk kelas positif, model berhasil mengklasifikasikan 1.919 data dengan benar *True Positive* dan salah memprediksi 127 data positif sebagai negatif *False Negative*. Hasil ini menunjukkan bahwa model memiliki kemampuan yang baik dalam mendeteksi kelas positif dengan jumlah prediksi benar yang jauh lebih tinggi dibandingkan kesalahan, meskipun masih terdapat kecenderungan kesalahan pada kelas negatif yang mengakibatkan nilai False Positive relatif tinggi. Pada penelitian Rahma et al. [16], metode LSTM terbukti mampu memberikan hasil yang baik dalam analisis sentimen, dengan capaian akurasi sebesar 81% serta nilai precision dan recall yang relatif seimbang, masing-masing sebesar 80%. Hal ini menunjukkan bahwa LSTM tidak hanya mampu mengklasifikasikan data dengan benar, tetapi juga konsisten dalam menjaga keseimbangan antara kemampuan mendeteksi sentimen positif maupun negatif.

4. KESIMPULAN

Analisis sentimen berbasis *Long Short-Term Memory* (LSTM) digunakan untuk memprediksi persepsi publik terhadap Program Makan Bergizi Gratis (MBG) berdasarkan 13.923 ulasan di X. Hasil menunjukkan dominasi sentimen positif sebesar 73,4% dan negatif 26,6%, memberikan gambaran dukungan sekaligus kritik masyarakat. Model LSTM, yang dilatih dengan pelabelan Lexicon-Based dan pembobotan Word2Vec, mencapai akurasi tertinggi 91,71% (train-test split 80:20) dengan presisi 89%, recall 90%, dan F1-score 89%. Arsitektur terdiri dari lapisan Embedding, LSTM 128 unit, Dropout 70%, dan Dense untuk klasifikasi dua kelas. Confusion matrix mengungkap kesalahan prediksi pada kelas negatif akibat ketidakseimbangan data. Hasil ini menunjukkan bahwa LSTM efektif dalam menangkap pola urutan teks, sehingga bermanfaat untuk mendukung pengambilan keputusan berbasis data dalam evaluasi kebijakan MBG.

Untuk meningkatkan hasil penelitian, disarankan melakukan optimasi hyperparameter, penyeimbangan data (oversampling atau undersampling), dan penambahan data pelatihan untuk memperkaya variasi. Eksplorasi model lain seperti BERT juga dapat dipertimbangkan untuk meningkatkan akurasi. Dari sisi pemanfaatan, hasil analisis sentimen dapat digunakan sebagai dasar perbaikan kebijakan, khususnya menindaklanjuti sentimen negatif melalui peningkatan distribusi dan kualitas gizi. Penelitian juga dapat diperluas dengan analisis temporal dan integrasi data dari platform lain untuk mendapatkan perspektif yang lebih holistik.

REFERENSI

[1] A. Sarjito, “Free Nutritious Meal Program as a Human Resource Development Strategy to Support National Defence,” *International Journal Administration, Business & Organization*, vol. 5, no. 5, pp. 129–141, 2024, doi: 10.61242/ijabo.24.454.

[2] A. Kiftiyah, F. A. Palestina, F. U. Abshar, and K. Rofiah, “Program Makan Bergizi Gratis (MBG) dalam Perspektif Keadilan Sosial dan Dinamika Sosial – Politik,” *Pancasila: Jurnal Keindonesiaan*, vol. 5, no. 1, pp. 101–112, 2025, doi: 10.52738/pjk.v5i1.726.

[3] D. Herdiana, “Implementasi Kebijakan Makan Bergizi Gratis (MBG): Faktor-faktor Pendorong dan Penghambat,” *Jurnal Ilmiah Multidisiplin*, vol. 3, no. 2, pp. 470–477, 2025.

[4] O. Manullang, C. Prianto, and N. H. Harani, “Analisis Sentimen Untuk Memprediksi Hasil Calon Pemilu Presiden Menggunakan Lexicon Based Dan Random Forest,” *Jurnal Ilmiah Informatika*, vol. 11, no. 02, pp. 159–169, 2023, doi: 10.33884/jif.v11i02.7987.

[5] I. Widyaya and W. Setiawan, “Analisis Framing Model Robert N. Entman dalam Representasi Publik Figur Politik: Episode ‘Dosa-Dosa Anies’ di Program ‘Kick Andy’ Metro TV,” *Sibatik Journal*, vol. 3, no. 1, pp. 103–118, 2023, [Online]. Available: https://publish.ojs-indonesia.com/index.php/SIBATIK

[6] N. Suwaryo, A. Rahman, D. Marini, U. Atmaja, and A. Basri, “Prediksi Penyakit Diabetes Untuk Pencegahan Dini Dengan Metode Regresi Linear,” *Bulletin of Information Technology (BIT)*, vol. 4, no. 2, pp. 313–319, 2023, doi: 10.47065/bit.v3i1.

[7] A. Raup, W. Ridwan, Y. Khoeriyah, S. Supiana, and Q. Y. Zaqiah, “Deep Learning dan Penerapannya dalam Pembelajaran,” *JIIP - Jurnal Ilmiah Ilmu Pendidikan*, vol. 5, no. 9, pp. 3258–3267, 2022, doi: 10.54371/jiip.v5i9.805.

[8] M. Ihsan, Benny Sukma Negara, and Surya Agustian, “LSTM (Long Short Term Memory) for Sentiment COVID-19 Vaccine Classification on Twitter,” *Digital Zone: Jurnal Teknologi Informasi dan Komunikasi*, vol. 13, no. 1, pp. 79–89, 2022, doi: 10.31849/digitalzone.v13i1.9950.

[9] L. Farsiah, A. Misbullah, and H. Husaini, “Analisis Sentimen Menggunakan Arsitektur Long Short-Term Memory (Lstm) Terhadap Fenomena Citayam Fashion Week,” *Cyberspace: Jurnal Pendidikan Teknologi Informasi*, vol. 6, no. 2, p. 86, 2022, doi: 10.22373/cj.v6i2.14687.

[10] M. V. Shyahrin, Y. Sibaroni, and D. Puspandari, “Penerapan Metode Long Short-Term Memory dan Word2Vec dalam Analisis Sentimen Ulasan pada Aplikasi Ferizy,” *Techno.Com*, vol. 22, no. 4, pp. 833–842, 2023, doi: 10.33633/tc.v22i4.9205.

[11] N. G. Ramadhan and A. Khoirunnisa, “Klasifikasi Data Malaria Menggunakan Metode Support Vector Machine,” *Jurnal Media Informatika Budidarma*, vol. 5, no. 4, p. 1580, 2021, doi: 10.30865/mib.v5i4.3347.

[12] R. Akbar, R. Santoso, and B. Warsito, “Prediksi Tingkat Temperatur Kota Semarang Menggunakan Metode Long Short-Term Memory (Lstm),” *Jurnal Gaussian*, vol. 11, no. 4, pp. 572–579, 2023, doi: 10.14710/j.gauss.11.4.572-579.

[13] I. Kurniasari, AchmadAchmad Arif Alfin2, and E. Widodo, “Implementasi Long Short-Term Memory (LSTM) dan Word Embedding Model pada Analisis Sentimen Layanan Uang Elektronik Ovo dan Link Aja,” *INFORMASI (Jurnal Informatika dan Sistem Informasi)*, vol. 15, no. 2, pp. 237–246, 2023, doi: 10.37424/informasi.v15i2.273.

[14] G. A. Lustiansyah, D. Widiyanto, and B. T. Wahyono, “Menggunakan Metode Long Short Term Memory,” *Senamika*, pp. 630–639, 2022.

[15] Y. A. Susetyo, H. A. Parhusip, S. Trihandaru, and B. Susanto, “LSTM-IOT (LSTM-based IoT) untuk Mengatasi Kehilangan Data Akibat Kegagalan Koneksi,” *Jurnal Teknologi Informasi dan Ilmu Komputer*, vol. 12, no. 1, pp. 175–186, 2025, doi: 10.25126/jtiik.2025129157.

[16] M. Z. Rahman, Y. A. Sari, and N. Yudistira, “Analisis Sentimen Tweet COVID-19 menggunakan Word Embedding dan Metode Long Short-Term Memory (LSTM),” *Jurnal Pengembangan Teknologi Informasi dan Ilmu Komputer*, vol. 5, no. 11, pp. 5120–5127, 2021, [Online]. Available: http://j-ptiik.ub.ac.id